

淘宝用户购物行为数据分析 — 项目报告

项目定位： 面向电商数据分析岗位的项目经历展示，体现分析框架设计能力、多工具协同能力与工程问题解决能力。

数据来源： 阿里云天池 UserBehavior 公开数据集，抽样前 110,000 行。

技术栈： MySQL 8.0 · Python (scikit-learn) · Tableau 2019 · DBeaver



项目摘要

针对淘宝 1 亿条用户行为数据，独立设计并完成一套全流程电商用户行为分析项目。采用 MySQL 完成数据清洗与多维聚合分析，运用 AARRR 漏斗模型、帕累托分析、商品四象限法和 RFM 模型，对用户行为转化路径、商品流量效率及用户价值分层进行系统诊断。引入 K-means 聚类算法对 RFM 人为规则分层结果进行交叉验证，发现人工分层存在 95.5% 的误分类偏差——SQL 评分标为“保持用户”的群体中，绝大多数实际为低频新用户，数据驱动分群显著优于经验阈值。最终在 Tableau 2019 中完成 10 张复合可视化图表（三轴组合图、蝴蝶图、气泡散点、帕累托图、散点矩阵等），将海量行为日志转化为可执行的运营决策依据。

分析模型： AARRR 漏斗 · RFM · K-means 聚类 · 帕累托分析 · 四象限法 · 蝴蝶图

STAR 法则项目描述

维度	内容
S (情境)	淘宝原始数据集包含约 1 亿条用户行为日志 (3.67GB CSV) , 需从中提取有效信息用于用户行为规律分析和运营策略制定。
T (任务)	独立完成从数据清洗、多维度分析到可视化报告全流程。核心任务: (1) 用户行为转化漏斗诊断, 定位流失关键环节; (2) 商品类目流量效率评估, 区分"流量型"与"成交型"类目; (3) 用户价值分层与分群合理性验证, 对比人为规则与机器学习聚类结果; (4) 输出可直接用于决策的可视化仪表板。
A (行动)	① 数据工程: 从原始 CSV 抽样 11 万行样本, MySQL 完成缺失值检查 (0 缺失)、五字段去重 (去除 46 行)、Unix 时间戳格式化 (新增日期时间/日期/小时三列)。采用 <code>CREATE TABLE AS SELECT</code> 替代全表 UPDATE 避免 C 盘写满中断; 将 MySQL 数据目录从 C 盘迁移至 F 盘, 从根本上解决磁盘瓶颈。 ② 分析建模: 编写 300+ 行 SQL 脚本, 构建 AARRR 漏斗四阶段分析、四条用户转化路径对比、商品四象限分类 (主打/问题/发展/长尾)、类目帕累托分析和 RFM 评分分层 ($R \times F$ 二维模型)。用 Python scikit-learn 对 745 个购买用户做 K-means 聚类 ($K=3$ 轮廓系数 0.509) , 与 SQL 人为规则结果做交叉表对比分析。 ③ 可视化设计: Tableau 2019 原生绘制 10 张复合图表: 三轴组合图 (PV柱状+UV折线+成交率折线)、24h 面积时钟图、类目蝴蝶图 (流量 vs 成交左右对称)、四象限气泡散点 (浏览$\times$购买, 气泡大小=转化率)、帕累托双轴图、RFM 环形图、R-F 散点矩阵 (趋势线+颜色分群)、SQL vs K-means 对比柱状图。采用蓝橙绿紫红五色体系统一视觉风格。 ④ 工程问题解决: 排查并修复 6 项工程问题: C 盘满导致 MySQL 崩溃$\rightarrow$数据目录迁移; 命令行中文编码报错$\rightarrow$全英文字段+DEFAULT CHARSET; DBeaver 一次性多查询报错$\rightarrow$改用 mysql 管道方式执行; MySQL 连接超时$\rightarrow$合并 ALTER+UPDATE 为单次 INSERT SELECT; Tableau 图表空白$\rightarrow$数据源隔离规则; RFM 分层阈值偏差$\rightarrow$K-means 交叉验证。
R (结果)	☑ 完成 5 项量化分析指标, 核心发现: 加购$\rightarrow$购买转化率 92.55% (购物车是转化关键点) ; 主流转化路径 C (加购后购买) 占 49.5%; 流量型类目 $\neq$ 成交型类目 (同排名下转化率差 7.4 倍) ; K-means 验证 SQL 分层的"保持用户"中 95.5% 实际为新用户, 数据驱动分群优于经验规则。☑ 输出 10 张可视化图表 + 1 份完整分析报告 (4 章 18 节) 。☑ 项目可完整复现——SQL 脚本一键执行、Python 脚本可复用并封装、Tableau 连接 MySQL 即可刷新。

第一章 · 数据集介绍

1.1 数据来源

阿里云天池公开 **User Behavior Data from Taobao** 数据集。原始全集约 100 万用户在 9 天内的全部行为日志, 总计约 1 亿条记录 (3.67GB) 。本项目抽样前 110,000 行作为分析样本, 在保证分析有效性的同时兼顾运行效率。

1.2 数据规模 (清洗后)

指标	数值
总行数	109,954
独立用户数	1,092
独立商品数	69,948
独立类目数	3,221
时间窗口	2017-11-25 ~ 2017-12-03 (9 天)

1.3 字段说明

字段	类型	说明
用户ID	BIGINT	用户唯一标识
商品ID	BIGINT	商品唯一标识
类目ID	BIGINT	商品所属类目
行为类型	VARCHAR(10)	pv(浏览) / fav(收藏) / cart(加购) / buy(购买)
时间戳	BIGINT	Unix 时间戳 (秒) , 范围 1511544070 ~ 1512316783

四种行为构成完整的电商转化链路：**pv (兴趣)** → **fav (意向)** → **cart (决策)** → **buy (成交)**。

1.4 数据清洗

清洗项	处理方式	结果
缺失值检查	5 列分别 COUNT(CASE WHEN ... IS NULL)	全部为 0
重复值去重	五字段完全匹配的 GROUP BY HAVING + DELETE	去除 46 行
时间格式化	FROM_UNIXTIME() 拆分为日期时间 / 日期 / 小时	新增 3 个衍生字段
异常过滤	WHERE 日期 BETWEEN '2017-11-25' AND '2017-12-03'	无异常数据
索引建立	user_id / behavior / 日期 / 小时 / 类目ID 分别建索引	查询提速

1.5 行为分布概况

行为类型	次数	占比
pv (浏览)	98,858	89.9%
cart (加购)	5,937	5.4%
fav (收藏)	2,875	2.6%
buy (购买)	2,330	2.1%

行为类型比例符合电商平台典型漏斗分布——浏览行为占绝对多数，购买行为约占总行为的 2.1%。

第二章 · 分析目标与思路

2.1 分析目标

用户侧： 对 1,092 位用户的 9 天行为数据进行建模，回答四个核心问题：

- 1. 用户什么时段最活跃？什么时候更愿意购买？（支撑营销排期）
- 2. 从浏览到购买的转化链中，哪个环节流失最严重？（支撑产品优化）
- 3. 哪些商品和类目值得投入资源？哪些是"伪流量"？（支撑精准推荐）
- 4. 如何对用户进行精准分层？人为规则 vs 数据驱动哪个更可靠？（支撑精细化运营）

平台侧： 将分析结论转化为可执行策略——什么时段投流、购物车如何优化、商品推荐权重如何调整、不同用户群体差异化运营方案。

2.2 分析模型选型

模型 / 方法	解决的问题	选择理由
AARRR 漏斗模型	用户转化链路诊断	电商数据分析的标准框架，逐环节量化转化率与流失点
多路径转化对比	不同行为路径效率差异	对比 4 条路径，找到最主流的转化通道
帕累托分析	类目流量集中度	验证二八法则，判断头部类目贡献度
四象限分析法	商品分类运营决策	浏览×购买矩阵，对 69,948 个商品制定差异化策略
蝴蝶图	流量 vs 成交可视化	直观揭示"流量型类目 ≠ 成交型类目"
RFM 评分模型	用户价值分层	电商领域最成熟的用户分层框架，R×F 二维评估
K-means 聚类	验证 RFM 分层合理性	数据驱动的无监督分群，与人为规则交叉验证

2.3 技术路线

原始 CSV (110,000行)
├─ MySQL：建库建表 → LOAD DATA INFILE → 数据清洗 → 字段衍生
├─ MySQL：GROUP BY聚合 → 10张分析结果表（KPI汇总/漏斗数据/类目排行/RFM分层等）
├─ Python：读取RF数据 → StandardScaler → K-means → 聚类结果回写MySQL
├─ Tableau：连接MySQL taobao库 → 10张复合可视化图表
└─ 分析结论 + 运营建议 → 可视化仪表板 → 完整项目报告

第三章 · 数据分析

3.1 用户行为习惯分析


3.1.1 核心 KPI

指标	数值	含义
总 UV	1,092	9 天内至少访问 1 次的独立用户
总 PV	109,954	所有用户的累计页面浏览量
成交用户数	745	至少完成 1 次购买的用户
整体成交率 (UV口径)	68.22%	745 / 1,092
人均 PV	100.7	平均每个用户浏览约 101 个页面
跳失率	7.44%	仅浏览未收藏/加购/购买的用户占比
复购率	66.31%	购买次数 ≥ 2 的用户占购买用户比

数据解读： 样本取自数据集前 11 万行，用户活跃度偏高——成交率与复购率均显著高于行业平均（通常 2%-5% 和 30%-40%）。这一选择偏差源于首部数据中活跃用户比例高，在结论中已明确标注。

3.1.2 每日 PV/UV 趋势与成交率变化

每日PV/UV趋势与成交率变化



日期天的 PV, UV 与 成交率 的趋势。颜色显示有关 PV, UV 与 成交率 的详细信息。


日期	PV	UV	购买用户数	成交率
2017-11-25	11,188	776	136	17.53%
2017-11-26	11,438	800	156	19.50%
2017-11-27	10,789	791	166	20.99%
2017-11-28	11,483	796	157	19.72%
2017-11-29	11,589	802	170	21.20%
2017-11-30	11,251	793	173	21.82%
2017-12-01	12,372	796	162	20.35%
2017-12-02	15,189	1,070	196	18.32%
2017-12-03	14,655	1,069	201	18.80%

发现：12月2-3日PV从~11,400激增至15,189（+33%），UV从~800增至1,070（+34%）——推测为双十二预热活动带来的流量涌入。但成交率从工作日的20%-22%降至18%——流量先涨、转化滞后。

分析方法细节：该图采用Tableau双轴组合图，主纵轴为PV柱状图（左），次纵轴为UV折线（右1）和成交率折线（右2），三条趋势线共享X轴，一张图同时展示量级、用户数与转化率的变化关系。

3.1.3 24 小时用户行为分布

工作表 3



小时的 行为次数 总和 的绘图。颜色显示有关 行为类型 的详细信息。


时段	行为特征	具体数据
0-6 时	深夜低谷	购买 < 20 次 / 小时
7-9 时	早间爬坡	各行为逐步回升
10-15 时	白天转化黄金期	13 点购买峰值 168 次/小时
16-18 时	午后平稳期	维持中高水平
19-22 时	晚间浏览高峰	21 点 PV 峰值 8,828/小时
23 时	急速衰减	购买仍保持 114 次/小时

发现：浏览行为峰值在 21 点（晚间），购买行为峰值在 13 点（午间）——两者不完全重合。这为分时段差异化运营提供了数据依据：晚间投活动引流，午间推个性化推荐促转化。

分析方法细节：该图采用面积叠加图，pv / cart / fav / buy 四种行为使用半透明面积层层叠加，pv 为最底层浅灰色底色，buy 为最顶层金色突出——一眼识别黄金时段的范围和强度。

3.1.4 用户活跃天数帕累托分析

用户活跃天数帕累托分析



活跃天数的用户数与正在沿着表(横穿)运行占比的总和的趋势。颜色显示有关用户数与正在沿着表(横穿)运行占比的总和的详细信息。


活跃天数	用户数	占比	累计占比
2	1	0.1%	0.1%
3	12	1.1%	1.2%
4	99	9.1%	10.3%
5	125	11.4%	21.7%
6	156	14.3%	36.0%
7	165	15.1%	51.1%
8-9	534	48.9%	100.0%

发现：近 50% 的用户在 9 天中活跃了 8-9 天，活跃 6 天以上者占 78%。样本用户粘性极高，这批用户是平台的核心资产。极低活跃用户（2-3 天）几乎不存在——再次证实首部采样偏差。

3.2 AARRR 漏斗转化分析

3.2.1 漏斗各阶段转化率

AARRR漏斗图



漏斗阶段	UV（独立用户数）	整体转化率	环比转化率
点击 (pv)	1,088	100.00%	—
收藏 (fav)	395	36.31%	36.31%
加购 (cart)	805	73.99%	203.80%
购买 (buy)	745	68.47%	92.55%

关键发现：

- 加购 → 购买转化率 92.55%——加入购物车的用户几乎必然会完成购买。这是转化链中最强的正向信号。
- 收藏 → 加购的环比转化率超过 100%（203.80%），说明加购用户数远超收藏用户数——购物车是比收藏夹更主流的行为路径。
- 整体点击 → 购买转化率 68.47%（1,088 位有点击用户中 745 位购买），再次印证样本用户的高活跃特性。

3.2.2 跳失率与复购率

指标	数值	解读
跳失用户数（仅 pv 无任何交互）	81	
跳失率	7.44%	远低于行业均值 30%-50%，用户购买意愿强
复购用户数（购买 ≥ 2 次）	494	
复购率	66.31%	超三分之二的购买者在 9 天内购买 2+ 次

3.2.3 四条转化路径对比分析

路径编号	转化路径	人数	占购买用户比	用户画像
C	点击 → 加购 → 购买	369	49.5%	🔗 绝对主流：典型购物车路径
D	点击 → 收藏 → 加购 → 购买	215	28.9%	深度决策：收藏+加购后才下单
A	点击 → 直接购买	82	11.0%	冲动/刚需：跳过中间步骤
B	点击 → 收藏 → 购买	76	10.2%	犹豫后成交：绕过加购直接买

核心发现：路径 C + D 合计 78.4%——两者都以"加购"为必经环节。 这意味着：

- 购物车是提升转化效率的第一优先级
- 直接购买仅占 11%，"跳过购物车直接下单"并非主流行为模式
- 路径 D 用户（收藏+加购后才买，29%）是谨慎决策型，对价格敏感——适合在收藏夹中推送降价提醒和优惠券

3.3 商品与类目偏好分析

3.3.1 类目 TOP 10 排行

类目 ID	点击量	购买量	转化率	覆盖用户	商品数
4756105	4,823 (#1)	23	0.48%	438	2,402
3607361	4,343 (#2)	22	0.51%	402	2,142
4145813	3,103 (#3)	32	1.03%	378	2,018
982926	2,899 (#4)	18	0.62%	435	1,835
2355072	2,859 (#5)	18	0.63%	392	1,794
2520377	2,006 (#6)	10	0.50%	314	1,437
1320293	1,811 (#7)	15	0.83%	384	1,254
4801426	1,810 (#8)	29	1.60%	353	1,226
2735466	1,188 (#10)	42 (#1)	3.54%	280	726
3002561	1,380 (#9)	26	1.88%	265	980

关键发现：点击量与购买量的排名并不一致。 类目 2735466 点击量仅排第 10，却拥有最高的绝对购买量（42 次）和最高的转化率（3.54%），是点击量第一的类目 4756105（0.48%）的 **7.4 倍**。推荐流量存在明显的"推得广但推不准"问题。

3.3.2 类目蝴蝶图：流量 vs 成交可视化




蝴蝶图左右对称展示 TOP 15 类目的点击量（左蓝）与购买量（右橙），中间标注转化率。

发现：高流量类目（左侧长条）往往对应右侧短条（低购买）——"流量型类目"≠"成交型类目"。 这说明曝光资源与转化效率存在错配，优化方向是提高具有高转化潜力的类目（右侧长条但左侧短条）的推荐权重。

3.3.3 类目帕累托分析

类目帕累托




类目id 的点击量与 累计占比 的趋势。颜色显示有关 点击量与 累计占比 的详细信息。视图按 类目id 进行筛选, 这会保留 20 个成员(总共 3,221 个)。

柱状图从高到低排列各类目点击量，红色折线为累计占比。符合电子商务典型的长尾分布——少数头部类目贡献了大部分用户流量。

3.3.4 商品四象限气泡图

类目价值四象限气泡图



点击量 总和 以及 收藏量 总和。颜色显示 覆盖用户数 总和。大小显示 转化率 总和。标记按 类目id 进行标记。为 类目id 显示了详细信息。在 收藏量 总和 与 点击量 总和 上筛选视图。收藏量 总和 筛选器包括大于和/或等于 0.0 的值并保留 Null 值。点击量 总和 筛选器包括大于和/或等于 0 的值并保留 Null 值。

以浏览量为 X 轴、购买量为 Y 轴构建类目散点矩阵，气泡大小代表转化率，颜色深浅代表用户覆盖数。两条参考线（X 均值 + Y 均值）将图切割为四个象限。

象限	商品数	占比	运营策略
主打款	78	0.1%	核心品：保库存、持续推广
问题款	16,474	23.5%	高浏览低购买——优化详情页、定价、评价
发展款	27	0.04%	低浏览高购买——需增加搜索权重和推荐位
长尾款	49,331	70.5%	评估是否下架或合并 SKU

发现：69,948 个商品中，真正有效的"主打款"仅 78 个（0.1%）。1/4 商品属于问题款——有充足曝光但无法转化为购买，是优化效率最高的群体。

3.4 RFM 用户价值分析

3.4.1 R/F 特征分布


由于数据集不包含消费金额（M），本分析采用 R-F 二维模型。

指标	最小值	最大值	平均值	含义
R 值（最近购买距 12-03 天数）	0	8	2.4	用户平均 2.4 天前刚买过
F 值（9 天内购买次数）	1	43	3.1	用户平均 9 天购买约 3 次

745 个购买用户的 RF 特征显示该群体整体活跃度极高。

3.4.2 SQL 评分法 RFM 分层

RFM分层



用户分层与用户id计数的总计%，颜色显示有关用户分层的详细信息。大小显示用户id总和。标记按用户分层与用户id计数的总计%进行标记。


R 值分段打分（0-1天=4分 ~ 7-9天=1分），F 值分段打分（1-5次=1分 ~ >50次=6分），R+F 综合评分确定用户层级。

用户分层	用户数	占比	平均 R	平均 F
重要价值用户	1	0.1%	0.0	43.0
重要发展用户	66	8.9%	0.4	9.4
重要保持用户	469	63.0%	1.3	2.8
一般挽留用户	209	28.1%	5.6	1.7

发现： SQL 评分法将 63% 的用户标为"重要保持用户"——但仔细看数据，这批用户的平均 F 仅 2.8 次，是否真的需要"保持/挽回"？这恰好引出了 K-means 交叉验证的必要性。

3.4.3 K-means 聚类验证

图11：K-means分层环形图



标签与用户id 计数的总计 %。颜色显示有关 标签 的详细信息。大小显示 用户id 计数。标记按 标签与 用户id 计数的总计 % 进行标记。

对 745 位购买用户的 R-F 值做 StandardScaler 标准化后，遍历 K=2~8 计算轮廓系数。**K=3 时轮廓系数达到最大值 0.509**，分群质量最优。

K-means 标签	用户数	占比	平均 R	平均 F	聚类中心特征
新用户	464	62.3%	1.2	2.6	近期活跃，低频购买
挽留用户	212	28.5%	5.6	1.8	已沉寂多日
价值用户	69	9.3%	1.1	10.4	高忠诚度，高频购买

3.4.4 ⚡ 核心发现：SQL vs K-means 交叉验证

图13a_SQL分层






图13b_Kmeans分层



工作表 11



R值总和以及F值总和。颜色显示有关用户分层1的详细信息。为用户id显示了详细信息。

将两种方法的结果按用户 ID 做交叉表分析：

SQL 分层 \ K-means 标签	价值用户	新用户	挽留用户
重要价值用户（1人）	√ 1	0	0
重要发展用户（66人）	50 →	16	0
⚡ 重要保持用户（469人）	18	448 →	3
一般挽留用户（209人）	0	0	√ 209

⚡ 本报告最重要的发现：SQL 评分为“重要保持用户”的 469 人中，K-means 将其中 448 人（95.5%）重新归类为“新用户”（低 F + 近 R）。

这意味着：

- SQL 人为经验阈值产生了大规模的误分类——R 值近但 F 值低的用户被错误标为“正在流失、需要保持”，而数据驱动的聚类清晰地指出他们属于“刚来不久、购买习惯尚未建立”的新群体
- 如果运营按 SQL 分层向这 448 人推送“老客挽回优惠券”，将造成营销资源的严重浪费
- K-means 识别的 69 位真·价值用户（平均 F=10.4），才是最值得投入 VIP 服务的核心群体
- 经验规则必须用数据驱动方法（无监督聚类 + 轮廓系数）做交叉验证，否则会出现大规模的“假标签”问题

第四章 · 结论与建议

4.1 核心发现汇总

#	发现	量化依据
1	加购是转化最关键的节点	加购→购买转化率 92.55% ；78.4% 的购买者以加购为必经步骤
2	流量 ≠ 成交	点击量 #1 的类目转化率仅 0.48%，而 #10 类目为 3.54%（差 7.4 倍）
3	购物车路径是主流	路径 C（加购后购）占 49.5%，路径 C+D 合计 78.4%
4	97.7% 的商品贡献可忽略	主打款仅 78 个（0.1%）；16,474 个问题款（23.5%）是首要优化目标
5	SQL 分层被 K-means 推翻	95.5% 的“保持用户”实际为低频新用户—— 数据驱动分群优于经验规则
6	浏览与购买存在时段错配	PV 峰值 21 点（浏览），购买峰值 13 点（成交）

4.2 运营策略建议

用户分层策略

用户群	占比	运营策略	具体措施
价值用户	9.3%	精细化 VIP	专属客服、新品优先试用、会员日定制折扣
新用户（主体）	62.3%	激活 + 培养	新人首单立减、7 日签到奖励、兴趣标签引导
挽留用户	28.5%	流失预警 + 召回	限时大额优惠券、降价 Push 推送、流失调研

商品优化策略

策略方向	行动	可影响范围
购物车挽留	加购 1h 未支付 → 推送限时优惠 + 库存告急提醒	覆盖 78% 购买路径
问题款优化	排查 16,474 个商品：详情页图片、定价、评价	23.5% 商品
发展款曝光	提高 27 个高转化低流量商品的搜索权重	成效高、实施快
流量重构	高转化类目（2735466 等）获得更多推荐位配额	推荐效率提升

时段策略

时段	策略
10-15 时	个性化推荐 + 限时优惠弹窗（转化率最高时段）
19-22 时	秒杀/直播/会员日/活动页投放（流量最大时段）

4.3 工程经验总结

遇到的问题	解决方案	可复用的原则
1 亿行 UPDATE 导致 C 盘写满	<code>CREATE TABLE AS SELECT</code> 替代 UPDATE	大数据写入避免 UPDATE，优先一次性 INSERT
命令行中文编码报错	纯英文字段名 + <code>--default-character-set=utf8mb4</code>	面向编码问题的防御性重写
DBeaver 一次性多查询报错	改用 <code>mysql < file.sql</code> 管道方式执行	大脚本优先命令行
MySQL 连接超时断开	合并 ALTER+UPDATE 为单次 INSERT SELECT	避免长事务中的空闲等待
Tableau 2019 图表渲染空白	每个工作表单独绑定数据源	Tableau 的数据源隔离机制
RFM 分层阈值偏差	K-means 交叉验证	经验规则必须有数据驱动方法验证

4.4 局限与改进方向

- 数据集不含消费金额（M）→ RFM 缺少 Monetary 维度，后续可引入客单价估算或使用行为序列权重替代
- 时间窗口仅 9 天 → 无法分析长期用户生命周期、季节性趋势
- 前 11 万行样本存在选择偏差 → 成交率（68%）等指标偏高，不可直接泛化到全量用户
- K-means 仅使用 R-F 二维特征 → 引入 M 维度后可实现更精细的三维聚类
- 后续方向：基于行为序列构建推荐系统模型，预测用户下一步购买意图

附录

A. 技术栈

工具	用途
MySQL 8.0	数据清洗、存储、SQL 聚合分析
DBeaver	SQL 编辑器与数据库管理
Python 3.8 (Anaconda3)	K-means 聚类
scikit-learn	KMeans + silhouette_score
Tableau 2019	10 张复合可视化图表
MySQL Connector/ODBC 8.0	Tableau ↔ MySQL 桥接驱动

B. 项目文件结构

taobao-analysis/	
├─ sample_110k.csv	# 样本数据（11万行）
├─ 淘宝用户购物行为分析-项目报告.md	# 本文档
├─ 研究框架思维导图.svg	# 可编辑SVG项目框架图
├─ Tableau看板汇总.twb	# Tableau工作簿
├─ sql/	
│ └─ complete_analysis.sql	# 全流程SQL（一键执行6阶段）
├─ python/	
│ └─ kmeans_rfm.py	# K-means聚类验证脚本
├─ 图1_全景趋势.png	# PV/UV/成交率三轴组合图
├─ 图2_24h行为分布.png	# 四种行为面积时钟图
├─ 图3_用户粘性帕累托.png	# 活跃天数帕累托双轴图
├─ 图4_AARRR漏斗.png	# AARRR漏斗条形图
├─ 图5_类目蝴蝶图.png	# 流量vs成交蝴蝶图
├─ 图6_类目气泡四象限.png	# 四象限气泡散点图
├─ 图7_类目帕累托.png	# 类目帕累托双轴图
├─ 图8_RFM分层环形图.png	# SQL评分法环形图
├─ 图9_K-means分层环形图.png	# K-means聚类环形图
├─ 图10_RF散点矩阵.png	# R-F散点矩阵+趋势线
└─ 图11_SQL vs K-means 分层对比柱状图.png	# 两种方法交叉对比柱状图

C. 核心数据速查

指标	数值
清洗后行数 / 用户数	109,954 / 1,092
UV / 成交率	1,092 / 68.22%
跳失率 / 复购率	7.44% / 66.31%
加购→购买转化率	92.55%
主流转化路径	C: 加购后购买 (49.5%)
K-means 最优 K (轮廓系数)	3 (0.509)
价值用户 / 新用户 / 挽留	9.3% / 62.3% / 28.5%
主打款 / 问题款 / 发展款 / 长尾款	78 / 16,474 / 27 / 49,331
SQL "保持用户" 误分类率	95.5% (448/469)

📅 报告完成日期：2026 年 6 月 28 日

📁 样本数据：sample_110k.csv (110,000 行, 约 4MB)

🔗 数据来源：阿里云天池 [User Behavior Data from Taobao](#)